

大語言模型運用於 企業管理與決策流程

從「會用聊天工具」進一步走到「能定義問題、驗證資訊、比較方案、管理風險，
並把 AI 放進真正的企業流程」。

1 這件事有價值嗎？

2 風險可以控制嗎？

3 現在做得到嗎？

4 怎麼證明有效？

課程設計與學習目標

這不是模型排行榜或工具操作課，而是一門「如何在管理與決策中正確使用 AI」的入門課。

上完三小時，學員應該能做到什麼？



理解

用簡單語言說明 LLM 如何產生答案，以及為什麼流暢不等於正確。



放進流程

把 AI 放進「定義問題、蒐集資料、比較方案、核准執行」的決策流程。



分配責任

分辨哪些工作可交給 AI，哪些判斷必須由人負責。



衡量效益

用時間、品質、收入、風險與成本衡量導入成果，而不是只看展示效果。



管理風險

辨識資料外洩、幻覺、偏見、權限與供應商依賴等問題。



Codex × ERP 實作

用 Codex 連結唯讀 ERP 資料，完成一次應收帳款、庫存或供應商情境分析，並說明證據、限制與人工決策。

課程設計與學習目標

這不是模型排行榜或工具操作課，而是一門「如何在管理與決策中正確使用 AI」的入門課。

0:00-0:50

理解、選題與查證

從採用趨勢與工作盤點開始，用四軸選擇用例，再理解 LLM 原理、限制與查證方法。

CHAPTER 01-03

0:50-1:00

休息

1:00-1:50

決策、資料與成效

拆解人機責任與 Agent 邊界，展示 Codex 分析 ERP，再用 ROI 與 KPI 衡量成果。

CHAPTER 04-06

1:50-2:00

休息

2:00-2:50

治理、部署與行動

從清楚指令走向 Agent 管理，處理治理與部署選擇，最後規劃可回復的小型測試。

CHAPTER 07-10

為什麼現在要學：採用正在增加，落差也在擴大

真正的競爭不只在「有沒有用 AI」，而在「能不能把 AI 變成可管理、可衡量的流程」。

20.2%

2025 年 OECD 企業回報使用 AI

52.0%

大型企業使用 AI 的比例

17.4%

小型企業使用 AI 的比例

企業 AI 採用率持續上升



資料來源：OECD：AI use by individuals surges across the OECD as adoption by firms continues to expand（2026 年 1 月 28 日）。OECD Data Explorer 可查詢原始統計。跨國統計口徑可能不同，適合用來說明趨勢，不宜直接當成台灣單一產業比例。



管理者真正要問的不是

「大家都在用哪一個模型？」

而是


- 我們正在解決哪個企業問題？
- 現在的資料、流程、技術與人力做得到嗎？
- 資料是否足以支持這個判斷？
- 錯誤的代價是什麼？
- 成果要用什麼 KPI 驗收？
- 誰有權核准與承擔責任？

為什麼現在要學：採用正在增加，落差也在擴大

理解 AI 從辨識、生成到推理與行動的發展，才能看懂今天企業面對的變化。

AI 發展脈絡：從辨識、生成到自主協作

早期 AI 主要處理辨識與分類，接著進入語言與內容生成，近年則逐步走向推理、工具使用與 Agent 協作。技術能力的增加，也讓工作影響從單一任務逐步延伸到流程設計與管理責任。



AI 發展時間軸：由感知與辨識、生成與語言統一，發展到推理、行動與自主編排。

為什麼現在要學：採用正在增加，落差也在擴大

真正的競爭不只在「有沒有用 AI」，而在「能不能把 AI 變成可管理、可衡量的流程」。

課堂練習

10 分鐘

盤點你的工作任務：哪些適合交給 AI？

請學員寫下自己一週內最常重複的三個工作任務，並逐一判斷：

1. 這個任務是否有清楚的輸入與輸出？
2. 哪些部分可以讓 AI 先做？
3. 哪些部分必須由人確認、判斷或負責？

適合優先

文字整理

會議紀錄、客訴分類、政策摘要、文件比對。

適合優先

產生第一版

郵件草稿、提案架構、問題清單、報告初稿。

需要覆核

分析與建議

客群洞察、供應商比較、需求預測、風險說明。

不宜自動決定

高風險決策

解僱、授信、醫療、法律責任與重大安全處置。

講師提示

請寫下自己一週內最常重複的三個工作任務，並標記哪些任務適合 AI 先做、哪些任務必須人工覆核。稍後在「用例優先排序」章節，會進一步評估它們是否有價值、風險可控、可執行且可驗證。

用例選擇與優先排序：先做有價值、風險可控、可執行、可驗證的事

第一個 AI 專案不應是最炫的項目，而應是最容易建立信任與量化成果的項目。

四軸評估法



價值 Value

- 節省多少時間或成本？
- 是否提升收入或服務品質？
- 影響多少人與多少流程？
- 問題是否經常發生？



可執行性 Feasibility

- 資料是否存在且可合法使用？
- 需要哪些工具、整合與權限？
- 誰負責資料、流程與例外？
- 使用者願不願意改變流程？



可驗證性 Verifiability

- 是否有明確 KPI 與基準線？
- 能否用小範圍或歷史資料測試？
- 結果能否客觀比較與重做？
- 錯誤是否能在影響擴大前被發現？



風險 Risk

- 錯誤的最大損失是什麼？
- 是否涉及個資或機密？
- 是否影響人的權益？
- 能否在執行前人工覆核？

互動工具：用例優先分數

四項各以 1–5 分評估。風險越高，優先分數會被扣除；可驗證性越高，越適合先做小型 PoC。這是初步討論工具，不是自動決策。

企業價值：3



資料與技術可行性：3



可驗證性與 KPI：3



錯誤與合規風險：3



優先分數

60

可以做小型驗證，但要先降低風險或補足資料。

用例選擇與優先排序：先做有價值、風險可控、可執行、可驗證的事

第一個 AI 專案不應是最炫的項目，而應是最容易建立信任與量化成果的項目。

適合第一批 PoC 的特徵

好起點	暫時不要先做
資料已數位化、來源清楚	資料散落、定義不一致、無人負責
目前流程重複且耗時	一年只執行一兩次、而且規則經常變動的任務，不適合作為第一個長期自動化 Agent
成果可抽樣或客觀驗證	答案高度主觀且沒有驗收標準
錯誤可在執行前被攔截	錯誤會直接造成重大財務、法律或人身損害
有明確業務負責人與 KPI	只有技術展示，沒有流程擁有者

選出最適合優先驗證的任務

拿出第一章寫下的三個任務，用前頁的互動工具各評一次，選出最高分的一項。

再檢查：錯誤能否及時攔截？

如果 AI 結果出錯，會由誰、在什麼時點、用什麼方式發現？

較容易控制

執行前有人覆核

例如會議紀錄由與會者確認，或客戶報價由業務在寄出前檢查。

風險較高

出錯後才被發現

若要等客戶反映或財務對帳才發現錯誤，就不宜作為第一批 PoC。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

用一句話理解大型語言模型

大型語言模型是一個根據前文，反覆預測下一個文字單位的系統。它從大量文本中學到語言、概念與關係的統計結構，因此能摘要、翻譯、分類、改寫與產生內容。

假設輸入「臺灣最高的山是」，模型會計算下一個 token 的可能性。「玉」的機率很高，接著再根據「臺灣最高的山是玉」預測下一個 token「山」。整段回答就是許多次預測串起來的。

臺灣

最高

的

山

是

→

玉

→

山

→

。



為什麼它看起來很聰明？

- 在大量文字中學到語言模式。
- 能根據上下文調整回答。
- 能把同一概念轉成不同形式。
- 能模仿專業文件的結構與語氣。



為什麼它會自信地說錯？

- 生成機制不是先查證再回答。
- 可能補出缺少但「看似合理」的資訊。
- 訓練資料可能過時、偏差或互相矛盾。
- 長對話中可能忽略前面重要限制。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

模型、知識、工具與工作流程不要混在一起

1 | 模型 Model 負責理解輸入、推理與生成內容；本身不保證知道企業最新資料，也不自然擁有資料庫或系統權限。

2 | 知識與上下文 Context / Knowledge 決定模型可以根據哪些資訊回答。包含 Prompt、企業規則與 RAG；RAG 是先檢索相關文件或資料，再放進模型上下文，不等於模型本身。

3 | 工具與行動 Tools / Actions 讓模型查詢 ERP、執行 SQL、呼叫 API、計算或建立工單。Tool 是可執行的功能；MCP 是連接應用程式、模型與工具 / 資料的協定，不是另一個模型。

4 | 工作流程 Workflow / Orchestration 決定下一步由誰控制。Application 通常走預先設計的流程；Agent 則能依目標選擇工具、觀察結果、重試或繼續執行，因此需要更嚴格的權限與監控。

講師提示 除了參數數量，先不討論 Transformer 數學或各版本排名。一般大眾只需掌握：模型負責生成，知識提供依據，工具負責行動，工作流程決定誰控制下一步。Skill 比較像可重複使用的工作方法，通常包含指示、資源與腳本，不等於 Tool 或 MCP。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

四類最常見的限制

時效性

模型未必知道最新事件、價格、法規、組織人員或內部狀況。

對策：搜尋、RAG、即時資料

真實性

可能產生不存在的來源、錯誤數字，或把相似事件混在一起。

對策：引用、抽查、交叉驗證

推理與計算

複雜多步驟容易累積錯誤；語言流暢並不保證數學正確。

對策：計算器、程式、規則引擎

上下文

文件太長時可能遺漏中間資訊，對話越長也可能忘記限制。

對策：分段、索引、摘要、檢索

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

一個簡單例子：9.11 與 9.9，哪一個比較大？

語言模型可能出錯的原因

「9.11」在文字中可能是日期、事件、版本或數字。模型如果沿著不適合的語境繼續生成，可能給出錯誤答案，還補上一段看似合理的解釋。


可驗證的處理方式

將 9.9 補成 9.90，直接比較可知 9.90 大於 9.11。精確計算應交給計算器或程式，LLM 負責解釋與整理。

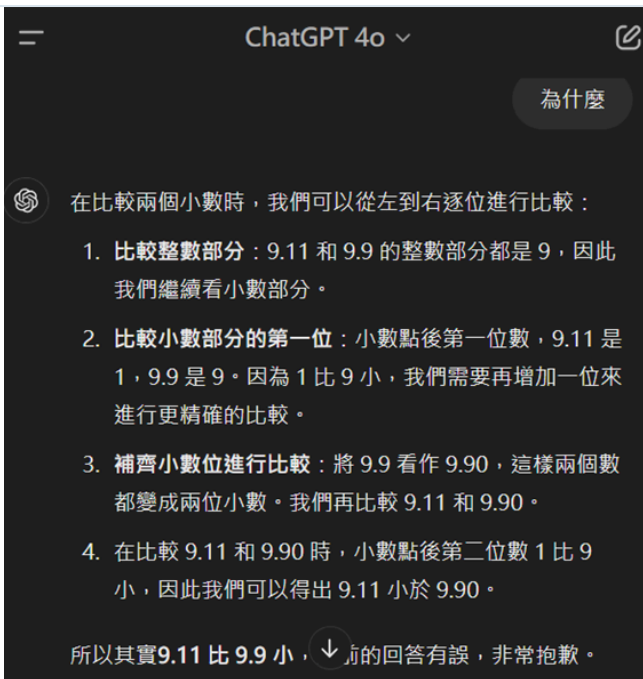
同一個問題，不同模型可能給出不同答案：以下截圖顯示，ChatGPT 4o 在這個例子中判斷錯誤；o1-preview 則回答正確。這不是證明某個模型永遠可靠，而是說明答案必須回到可重做的比較與計算。



ChatGPT 4o：先回答「9.11 比 9.9 大」，但沒有正確進行小數位比較。



ChatGPT o1-preview：在這個案例中回答「9.9 比 9.11 大」，並顯示思考時間。



追問「為什麼」：模型補充了整數部分、小數第一位與補齊小數位的比較步驟。

可以要求模型說明依據，但不能把說明當成證據

追問「為什麼」有助於把答案拆成可檢查的中間步驟。這次回答採用的比較路徑是：

1. 先比較整數部分：9.11 與 9.9 都是 9。
2. 再比較小數第一位：1 小於 9。
3. 將 9.9 補成 9.90，再與 9.11 對齊比較。

這讓人更容易發現模型到底採用了什麼判斷方式，也方便人工重做。但「看起來有推論」不代表推論一定正確；重要任務仍要交給計算器、程式或可查證的資料來源驗證。

教學提示：可請學員比較第一次回答、追問後回答與實際數值，觀察「答案、理由、證據」是三件不同的事。

管理重點：有步驟、有格式、有自信，都不是證據。重要答案必須能指出資料來源、重做中間計算，並由適當的人負責核准。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

另一個例子：潮汐查詢中的「看似精準」

潮汐時間與潮位不是只靠一般常識就能回答的資料。它會受到觀測地點、日期、潮汐站、基準面與資料更新影響，因此回答中如果缺少明確來源，就算列出精確到分鐘的時間，也不代表可靠。

案例：同樣查詢「5/27 號頭城潮汐」，截圖中的兩個模型給出了不同的時間與潮位；其中一個回答還加入了天氣與出門提醒。這些內容看起來完整，但必須先確認地點、年份與官方潮汐資料。

gemini

幫我查 5/27 號頭城潮汐

工作或下海衝浪要留意，2026年5月27日（星期三，農曆四月十一）頭城地區的潮汐預報資料如下：

當天屬於小潮，潮差較小。

潮汐時間表

滿潮：03:39 (相對潮高約 55 cm)

乾潮：10:20 至 11:00 之間 (依鄰近海域推算)

滿潮：16:30 至 17:15 之間 (依鄰近海域推算)

乾潮：22:50 左右 (依鄰近海域推算)

💡 衝浪小提醒：

當天是小潮，海水起伏比較溫和。如果是去頭城（如烏石港、竹安）衝浪或看海，清晨滿潮過後退潮的階段，或是下午乾潮返漲的時段，通常浪形會比較有變化，出發前建議再瞄一眼當天的即時海況與風向！

chatgpt

幫我查 5/27 號頭城潮汐

5/27（週三）頭城 的潮汐如下：

潮汐	時間	潮位（相對當地平均海平面）
滿潮	03:39	39 cm
乾潮	10:25	-47 cm
滿潮	16:44	26 cm
乾潮	22:11	-20 cm

當天屬於「小潮」。 [cwa.gov.tw](#) +1

官方潮汐查詢：
[中央氣象署潮汐預報](#) ↗

截圖比較： Gemini 與 ChatGPT 對同一個潮汐問題提供了不同的潮時與潮位；ChatGPT 顯示了中央氣象署潮汐預報的來源提示，但仍應點開官方資料核對。

可能的幻覺與風險

- 沒有確認「頭城」對應的實際潮汐站。
- 沒有明確指出年份、時區與潮位基準。
- 把推估或一般性提醒寫成像官方預報的精確資料。
- 引用來源標籤不等於真的完成來源核對。

正確的驗證流程

1. 確認地點、日期、年份與使用目的。
2. 優先開啟中央氣象署等官方潮汐資料。
3. 比較潮時、潮位、測站與資料基準是否一致。
4. 若要安排出海、釣魚或安全活動，保留人工確認與現場判斷。

管理重點：生活查詢也可能需要外部即時資料。當答案涉及時間、地點、天氣、交通或安全時，AI 應該協助找資料與整理比較，不應取代官方來源與人的最後判斷。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

降低幻覺的六層防線

前四層可以直接寫進指令，讓 AI 的回答有資料與格式防線；後兩層屬於流程控制，不能只靠 Prompt 解決。

1

限定任務

明確說明目標、資料範圍、禁止事項與輸出格式。

2

提供來源

使用指定文件、企業知識庫或官方資料，不讓模型任意補空白。

3

使用工具

日期、計算、查價、庫存與統計交給可驗證的系統處理。

4

要求揭露依據

要求列出關鍵假設、引用、計算式與不確定之處，而不是只給結論。

5

設定人工關卡

對外發布、付款、報價、人事與法律動作，執行前必須有人核准。

6

持續監測

抽樣檢查錯誤、記錄模型版本、追蹤異常並改善提示與資料。

寫指令時的快速檢查：先限定資料來源與任務範圍，再說明輸出格式；要求 AI 分開列出事實、推論與未知，並標示引用與計算依據。最後確認哪些行動仍須人工核准。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

拿到 AI 答案後，管理者先做五項判讀

這不是教 AI 用固定格式回答，而是管理者閱讀任何 AI 輸出時的檢查框架：先找出資料支持的事實，再分開推論與未知，接著評估錯誤後果，最後決定採用、查證或暫停。

已知

可由指定資料直接支持的事實。

推論

根據哪些資料與假設形成的判斷。

未知

目前缺少哪些資料，還無法判斷什麼。

風險

如果推論錯誤，可能帶來哪些後果。

下一步

需要向誰確認、查哪個系統，或補什麼資料。

判讀順序：先看證據，再分開推論與未知，接著評估風險，最後決定下一步。

例子：ERP 應收帳款分析

AI 查詢 ERP 後，產生以下結構化摘要：

已知：系統顯示某客戶有 3 筆逾期發票。

推論：可能需要優先聯繫。

未知：尚未確認客戶是否已付款，或是否存在帳務爭議。

風險：若直接催收，可能造成客戶關係問題。

下一步：先查銀行入帳與 CRM 紀錄，再由財務確認。

AI 先做

整理 ERP 資料，標記逾期項目，產生初步判斷。

系統檢查

檢查欄位、計算與來源是否存在且可追溯。

人工負責

確認資料是否最新，決定是否催收與由誰核准。

資料查對，不代表推論正確。

系統可以協助確認資料、計算與格式；推論是否合理、風險是否可接受，仍需要人依照業務情境判斷。可追溯性是判斷的起點，不是結論。

LLM 如何產生答案，以及為什麼會出錯

LLM 以機率生成文字；理解它如何工作、容易在哪裡出錯，才能設計查證與人工覆核。

快速練習

8 分鐘

看似完整的答案，哪裡還不能相信？

請把下面這段 AI 摘要當成「初稿」，逐句標記：哪些可以保留？哪些需要回到來源？哪些其實是 AI 的推論？

根據 2025 年 3 月的資料，公司第二季雲端支出將增加 18%，主要原因是新法規要求企業保留至少 7 年的 AI 使用紀錄。由於目前已有 80% 的部門使用 AI，建議公司立即擴大 AI 預算，預計可提升整體工作效率 25%。

請考慮

1. 哪些是可直接採用的文字整理？
2. 哪些數字必須回到原始資料？
3. 哪些句子是推論而不是事實？
4. 如果要送給主管，還缺什麼？

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

從判讀 AI 輸出，到完成一個可負責的決策

上一章先練習看懂 AI 回答中的事實、推論、未知與風險；這一頁把同樣的查證與責任觀念，展開成一個完整的管理決策流程。AI 可以參與多個步驟，但不能取代最後的權責判斷。

STEP 1

定義問題

要改善什麼？成功標準是什麼？

STEP 2

蒐集資料

有哪些內外部資料？品質如何？

STEP 3

描述現況

發生了什麼？規模、趨勢與異常。

STEP 4

分析原因

提出假設，分開證據、反證與未知。

STEP 5

產生選項

提出替代方案，說明各自的前提與影響。

STEP 6

比較風險

一起看價值、風險、可執行性與可驗證性。

STEP 7

核准執行

確認權限、例外與責任，由有權責的人決定。

STEP 8

監測修正

依 KPI、例外與實際結果查核並調整。

這八步驟不是另一套 Prompt 格式，而是管理者使用 AI 時的查核路徑：

先找出問題：定義問題、蒐集資料、描述現況，再分析原因。

再做出選擇：產生選項，並用價值、風險、可執行性與可驗證性比較。

最後負責到底：由人核准執行，持續看 KPI 與例外，必要時修正或停止。

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

每一個階段，AI 的角色都不同

階段	AI 可以協助	人必須負責	應留下的產出
定義問題	整理背景、提出澄清問題	決定目標、範圍與利害關係人	問題陳述、成功指標
蒐集資料	搜尋、分類、去重與初步摘要	確認授權、資料口徑與品質	資料清單、來源、更新時間
描述與診斷	發現模式、異常與可能原因	區分相關與因果，補充情境	現況摘要、假設清單
產生選項	提出替代方案、反方觀點	排除違法、不可行或不符合價值的方案	方案列表、必要條件
比較風險	情境模擬、敏感度與利弊整理	設定權重與風險容忍度	評分表、風險與未知事項
核准執行	準備報告、任務與溝通草稿	做最後決定、簽核並承擔責任	決策紀錄、核准人、執行計畫
監測修正	追蹤 KPI、偵測偏移與例外	判斷是否調整、暫停或撤回	成效報告、事件與改善紀錄

好決策的最低標準：知道問題是什麼、資料從哪裡來、有哪些選項、假設與風險是什麼、誰核准，以及決定後如何追蹤結果。

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

五種決策用途，風險逐步增加

低風險

描述 Descriptive

「上個月發生了什麼？」例如銷售摘要、客訴分類、會議紀錄。

低至中

診斷 Diagnostic

「為什麼發生？」AI 可提出可能原因，但要避免把相關性當因果。

中風險

預測 Predictive

「接下來可能發生什麼？」必須說明資料期間與誤差。

中至高

建議 Prescriptive

「我們應該怎麼做？」要揭露權重、假設與替代方案。

高風險

執行 Autonomous

「直接採取行動。」涉及付款、通知、修改資料或影響他人權益。

風險原則

越靠近真實世界的執行，越需要最小權限、人工核准、完整紀錄與可回復機制。

課程練習

選一項需要判斷與取捨的工作

請從工作中選一項需要判斷與取捨的事情，例如供應商選擇、人力排班、預算分配或客訴處理，依照八步驟檢視：問題是否明確、資料是否足夠、現況是否掌握、原因是否經過驗證、是否提出可比較的選項、成本與風險是否評估、由誰核准執行，以及如何監測與修正結果。若仍有關鍵項目說不清楚，先不要急著導入 AI。

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。



AI 適合負責

- ✓ 大量資料的搜尋、分類、摘要與格式轉換
- ✓ 產生報告、郵件、提案或問題清單的第一版
- ✓ 找出異常、模式與需要人工注意的項目
- ✓ 提出多個方案、反方觀點與可能風險
- ✓ 依照明確規則執行低風險、可回復的任務
- ✓ 持續監測指標並發出提醒



人必須負責

- ✓ 決定真正要解決的問題與成功標準
- ✓ 判斷資料是否合法、完整且適合該用途
- ✓ 處理價值衝突、倫理、政治與組織情境
- ✓ 設定風險容忍度與決策權重
- ✓ 核准對人、財務、法律及安全有重大影響的行動
- ✓ 對最終結果與補救措施負責

協作

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

三種人工參與模式

Human in the Loop

AI 每次提出結果後，由人確認才能繼續。適合報價、對外信件、敏感資料與新上線流程。

Human on the Loop

AI 在限制內自動運作，人監控例外並可隨時介入。適合已成熟的分類、提醒與排程。

Human out of the Loop

執行期間不需要人即時介入。只有低風險、規則穩定、可回復且已充分驗證的任務才適合；仍需事前設計與事後稽核。

三個情境例子

Human in the Loop

筆錄、會議與醫療診斷輔助

AI 可完成語音辨識、摘要、病歷整理與風險提示；但主持人、負責人或醫師必須確認人名、數字、決議、診斷與處置後，才能發送、入庫或進入醫療流程。

Human on the Loop

柵欄模型與使用監控

系統自動偵測敏感內容、異常用量或不當使用，平時自動阻擋、告警與記錄；只有例外案件、申訴或高風險事件才由人介入處理。

Human out of the Loop

低風險自動爬蟲

依固定規則抓取公開網頁並更新索引，不在執行中逐筆請人確認。前提是來源公開、權限清楚、頻率受控、結果可回復，且有事後抽查與停用機制。

判斷方法：不要先問「AI 能不能做」，先問「人要在每一步確認、只監控例外，還是完全不參與即時執行？」風險越高，人的介入就越接近流程核心。

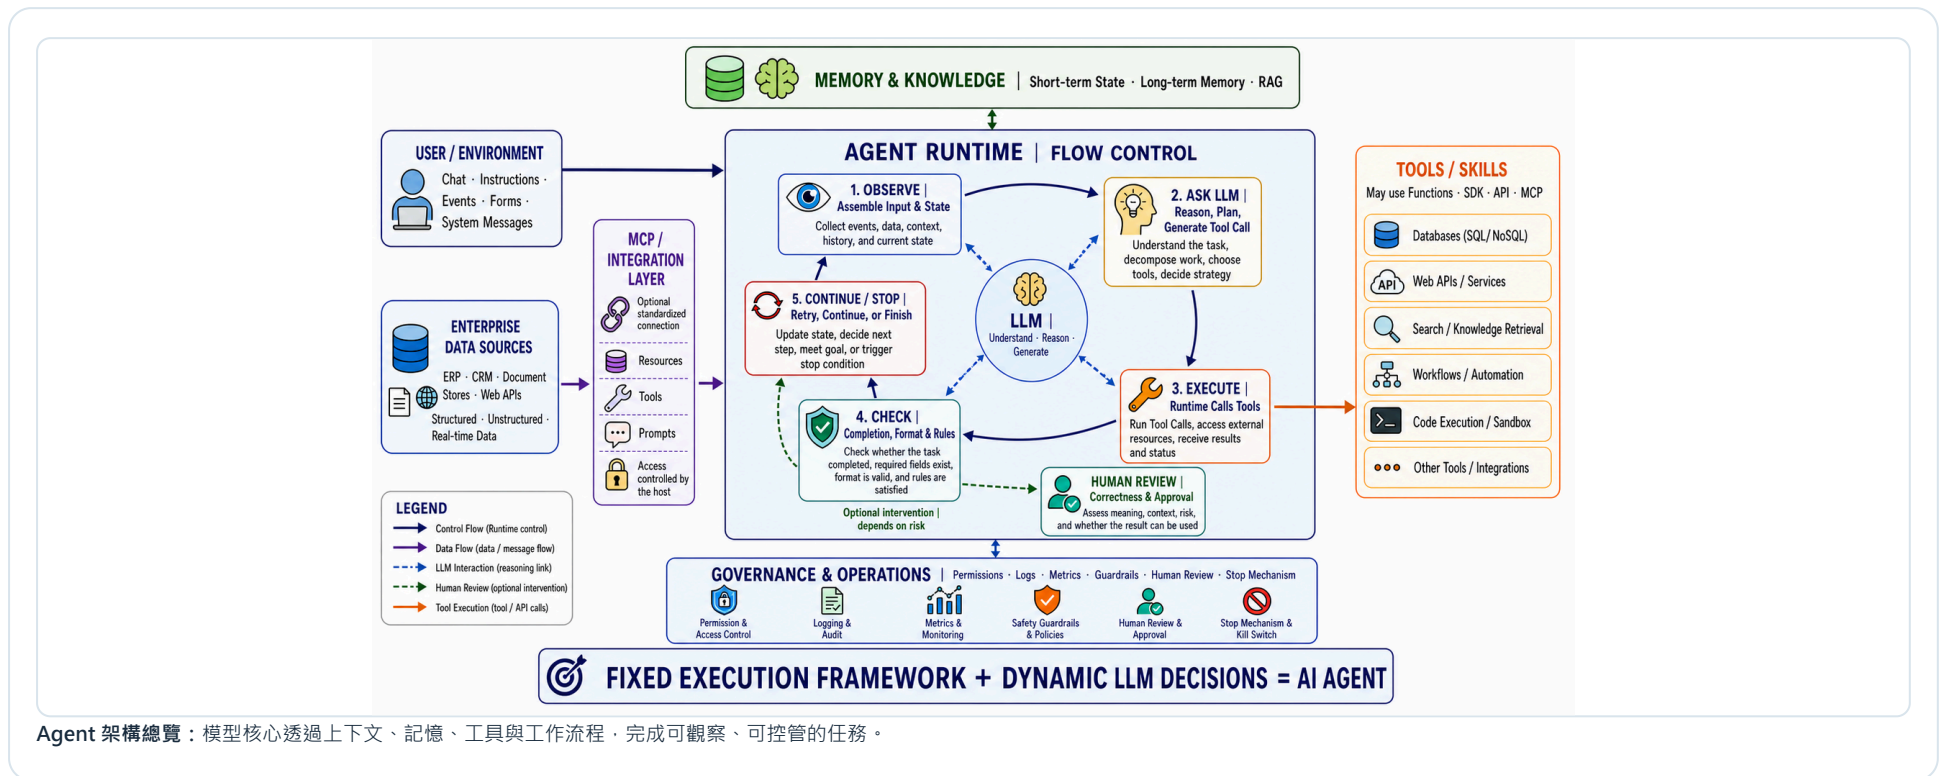
錯誤觀念：「既然 AI 建議的，所以沒有人負責。」正確做法是事先指定資料負責人、系統負責人、業務核准人與事件處理人。

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

現在的 AI Agent，如何組成一個可管理的系統？

前一頁說明了人應該如何參與 AI 流程；這張架構圖進一步拆解 Agent 如何把模型、資料、工具與控制循環放進同一個可管理的系統。Agent Runtime 負責控制觀察、呼叫 LLM、執行工具、檢查結果，以及繼續、重試或停止；LLM 則負責理解、推理與產生下一步決策。



Agent 架構總覽：模型核心透過上下文、記憶、工具與工作流程，完成可觀察、可控管的任務。

圖中的主要元件

- **LLM Core**：負責理解、推理與生成。
- **Memory**：保存對話脈絡、長期資料或知識索引。
- **MCP Layer**：一種可選的標準化連接方式，可暴露 Resources、Tools 與 Prompts；資料與工具也可以透過 Function、SDK 或 API 連接。
- **Agent Skills**：提供可重複使用的任務方法與工具組合。
- **Runtime Loop**：Runtime 整理輸入與狀態，請 LLM 推理與規劃，呼叫工具執行，再由規則檢查完成度；高風險或不確定時，交由人員判斷是否正確與核准。

管理者真正要管的是什麼？

- 哪些資料可以讀取，哪些工具可以執行？
- 哪些動作需要人工核准或雙重確認？
- 如何留下日誌、追蹤錯誤與衡量成本？
- 什麼條件下必須停止、轉交給人或回復原狀？

因此 Agent 的能力越高，權限、監控、人工介入與驗收標準也要同步升級。

先記住：Agent 不是「有工具的聊天機器人」而已；它是一個可以在受控範圍內決定下一步的工作流程。

AI 進入決策流程：角色、Agent 與人工責任

AI 可以協助定義問題、整理資料、比較方案，甚至透過 Agent 使用工具；但目標、權限、核准、例外與責任仍由人掌握。

設計一個可管理的 Agent | 本課程用 Codex 示範

學員不必學會 CLI，也不必自行開發 Agent；先用 Codex 看懂一個 Agent 如何讀資料、使用工具、提出建議，再判斷哪些步驟值得自動化。

先把工作邊界畫清楚

- 1. 觸發：什麼事件或需求會啟動任務？
- 2. 輸入：可以讀哪些資料？哪些資料禁止使用？
- 3. 產出：要摘要、分類、建議、草稿，還是有限執行？
- 4. 行動：哪些動作可自動做？哪一步一定要人工核准？
- 5. 驗證：用什麼 KPI、基準線與停止條件判斷有效？

課程示範：用 Codex 管理一個任務

- 1. 用自然語言說明工作目標與限制。
- 2. 指定可讀的資料、參考文件與既有 skill。
- 3. 讓 Codex 分析、引用來源並產生草稿或建議。
- 4. 由人員核准對外回覆、更新紀錄或其他行動。
- 5. 用時間、錯誤率、人工修改率等 KPI 檢查成效。

Agent 不只一種做法：管理者要先看懂取捨

路線	適合情況	管理上要注意
Codex Claude Code CLI	用自然語言探索資料、分析問題、產生草稿、撰寫程式或建立 skill；適合從既有專案開始。	兩者都能讀寫檔案與呼叫工具；需清楚界定資料範圍、工具權限與人工核准點。
現成 Agent 工具	例如 OpenClaw、Hermes Agent，適合需要持續執行、多步驟任務與工具整合的技術團隊。	部署、權限、成本與操作紀錄要有人負責；本課程不要求學員操作。
自行用 LangChain 建置	需要高度客製、長期整合或產品化的場景。	控制力最高，但也要承擔測試、維護、資安與版本管理。

管理上的四個檢查：這個 Agent 解決什麼價值？風險如何控制？資料、工具與流程做得到嗎？KPI 能不能證明它真的改善工作？

從 ERP 資料到管理洞察：用 Codex 找證據，用 Skill 固化規則

ERP 記錄交易，AI 協助跨表找出訊號；但原因判斷、風險取捨與行動核准仍由管理者負責。

ERP 有資料，不代表管理者已經有答案

課堂情境：這是一套為 AI 分析展示建立的模擬 ERP。資料涵蓋銷售、採購、庫存、毛利、應收帳款與業務員，但管理者真正想知道的不是「有幾張單」，而是「哪裡正在失血、為什麼，以及接下來要確認什麼」。

範例系統：[JavisOfWeiYen/my_erp](#)

資料期間

18 個月

2024-12 ~ 2026-05

交易資料

1,576 張

已確認銷售單

客戶資料

30 家

模擬企業客戶

商品資料

37 項

不同產品 SKU

ERP 擅長記錄

交易事實分散在不同表格

- 客戶買了什麼、何時下單、由誰負責
- 確認訂單當下的售價與成本
- 應收是否付款、逾期多久
- 庫存、進貨與盤點異動

管理者真正想問

從紀錄轉成可查核的決策問題

- 為什麼 H100 賣得好，毛利卻是負的？
- 哪些客戶同時出現訂單下降與付款惡化？
- 哪些逾期應收值得優先確認？
- 哪些 SKU 已經需要重新議價？

1

提出問題

從管理痛點出發。

2

讀取 Skill

取得資料定義與規則。

3

查詢 seed.db

留下可重算的證據。

4

提出解讀

區分事實、假設與未知。

5

主管查核

核准下一步行動。

本章重點：學員不需要學會操作 ERP、寫 SQL 或開發 Agent；只要看懂 AI 如何利用企業資料提出有證據的管理建議，以及管理者應該在哪裡介入。

從 ERP 資料到管理洞察：用 Codex 找證據，用 Skill 固化規則

先用一個有明確轉折、可以重算的問題，示範 Codex 如何從 ERP 資料找到管理訊號。

現場示範：H100 為什麼賣得好卻在虧錢？

請先完整閱讀 `src/skills/my-erp-analysis/SKILL.md`，並依其中規則按需讀取 `schema.md` 與 `examples.md`。

問題：2025 上半年 H100 銷售很好，為什麼毛利反而是負的？2025-10 之後怎麼回穩？

請只讀取 `seed.db`，列出可重算的數據；把「資料支持的事實」、「可能原因」與「資料庫無法回答的未知」分開，不得修改資料。

讀規則

先確認怎麼算

只看 confirmed 訂單；歷史毛利使用銷售確認當下的 `unit_cost` 快照。

查證據

比較轉折前後

依月份重算銷量、加權平均售價、成本、毛利率與毛利。

交付判讀

事實與假設分開

說明資料能證明什麼、不能證明什麼，以及下一步由誰確認。

期間	銷量	加權平均售價	加權平均成本	加權毛利率	毛利
2025-01 ~ 09	21	NT\$ 966,000	NT\$ 1,050,000	-8.70%	-NT\$ 1,764,000
2025-10 ~ 2026-05	9	NT\$ 952,000	NT\$ 840,000	+11.76%	NT\$ 1,008,000

資料支持的結論

售價沒有上升，成本卻下降 20%；毛利回升主要由成本下降解釋。立通科技是 H100 最大買家，共買 12 張，該 SKU 累計毛損 NT\$ 999,600。

資料庫不能直接證明

成本下降究竟來自市場供需、原廠政策或其他原因，ERP 沒有足夠欄位；必須補供應商文件、採購備註或外部來源。

管理上的差別：Codex 可以指出異常、提出報價控制建議；是否調價、暫停接單或建立毛利門檻，仍由產品、採購與業務主管決定。

從 ERP 資料到管理洞察：用 Codex 找證據，用 Skill 固化規則

一次問對不代表每次都會做對；要把資料定義、工作規則與驗收方式變成可重複使用的企業知識。

Skill 不是魔法，是給 AI 的企業工作說明

這套 skill 原本可供 OpenClaw 使用；課堂第一版直接讓 Codex 讀取同一個資料夾。重點不是平台名稱，而是把企業特有、不能猜錯的規則交代清楚。

SKILL.md

角色與邊界

何時啟動、回答語言、唯讀規則、禁止事項與輸出結構。

schema.md

資料口徑

表格關係、欄位定義、毛利與帳齡算法，以及常用查詢模式。

examples.md

合格範例

示範如何從問題、查詢、證據走到事實、假設、未知與建議。

seed.db

可重算證據

所有數字都必須回到實際資料查詢，不能沿用記憶或舊範例。

沒有企業規則時，AI 很容易在「看似合理」的地方算錯

容易犯的錯	Skill 內的修正規則	為什麼重要
用商品目前成本回算歷史毛利	使用訂單確認當下的 <code>sales_order_items.unit_cost</code>	避免把後來漲跌的成本套回舊訂單
把草稿與取消單算進業績	只分析 <code>status='confirmed'</code>	尚未成立的交易不能當營收
用今天日期計算 demo 帳齡	固定以 2026-05-22 為分析日	確保每次課堂展示都能重現
看到逾期就自動停信用	AI 只排序與建議，信用變更必須人工核准	資料分析不能取代正式授權

示範 Codex 協助撰寫 Skill：

請檢查 `seed.db` 的資料表、計算陷阱與管理風險，替 ERP 分析助理整理一份可重複使用的工作規則。必須包含觸發情境、資料來源、唯讀限制、計算口徑、回答格式、未知處理與人工核准點；詳細 `schema` 與案例分開保存，避免把所有內容塞進 `SKILL.md`。

管理者要提供的不是程式碼：哪些數字代表正式交易？毛利怎麼算？哪些資料不能使用？什麼行動一定要核准？Codex 可以協助把答案整理成 skill。

從 ERP 資料到管理洞察：用 Codex 找證據，用 Skill 固化規則

Skill 讓分析比較一致，但不會把相關性變成因果，也不會取得管理者才有的授權。

主管查核：AI 找到訊號，不等於可以直接行動

現場第二問：「祥豐電腦最近怎麼了？」讓 Codex 依同一套 skill 跨查訂單、營收與應收帳款，再由主管判斷下一步。

Codex + Skill 輸出

資料支持「客戶風險升高」

指標	2026-02	2026-03	2026-04	2026-05
訂單數	5	1	1	0
月營收	NT\$ 951,510	NT\$ 94,653	NT\$ 237,800	NT\$ 0
AR 付款率	60%	0%	100%*	—

* 2026-04 只有 1 筆樣本，不能單獨解讀為付款狀況恢復。

其他風險：尚有 14 筆 AR 未結清，其中 11 筆逾期 90 天以上，餘額 NT\$ 3,056,982。

主管查核

資料沒有告訴我們真正原因

- 可確認：訂單、營收與付款訊號同時惡化。
- 仍未知：客戶是否轉向競品、專案結束、預算延後或經營困難。
- 先查核：業務訪談紀錄、爭議款、付款承諾與近期專案。
- 再決策：由業務與財務主管評估拜訪、催收或信用條件。

不能直接做：Agent 不得自行聯繫客戶、寄催款函、停止信用或把客戶標記為「確定流失」。

把結果放回四個核心問題

有價值

提早發現客戶與應收風險，集中有限管理時間。

風險可控

只讀分析；對外聯繫與信用變更保留人工核准。

可執行

ERP 已有訂單、付款與客戶資料，能跨表查詢。

可驗證

追蹤後續訂單、回款、有效聯繫率與逾期餘額。

銜接下一章：AI 找出管理訊號後，還要判斷這項分析是否產生實際價值，以及投入的成本是否值得。下一章先從 ROI、TCO 與 KPI 說明如何衡量 AI 導入成果；接著在 [Chapter 07 | AI 任務說明五要素](#)，再把問題寫成可管理、可驗收的任務。

ROI、TCO 與成效衡量：展示成功不等於企業成功

AI 專案要同時計算效益、完整成本與風險。省下的時間若沒有被重新運用，也不一定會變成財務成果。

先分清楚「效益」與「成本」

+

年度效益

- 節省工時 × 每小時完整人力成本
- 營收或轉換率提升
- 錯誤、退貨、客訴與停機減少
- 決策與交付週期縮短
- 風險損失被避免

—

年度總成本

- 模型訂閱或 API 用量
- 硬體、雲端與網路
- 資料清理與系統整合
- 測試、資安、治理與稽核
- 教育訓練、維運與變更管理

年度淨效益 = 年度可實現效益 - 年度總成本

投資報酬率 ROI = 年度淨效益 ÷ 初始投資 × 100%

回收期間（月）= 初始投資 ÷ 每月淨效益

「可實現效益」要保守估算。例如 AI 每月節省 100 小時，不表示公司一定少付 100 小時薪資；更合理的說法可能是員工能把其中 60% 轉用於服務客戶或完成更多任務。

互動工具：簡易 ROI 試算

目前每月投入工時

400

每小時完整人力成本（元）

800

預計節省時間比例（%）

30

節省效益可實現比例（%）

60

估計原本工作時間中，有多少比例理論上可以被自動化。例如每月 400 小時，預計可減少 30%。

不是所有預計節省都能真正發生；要扣除導入阻力、人工覆核、使用率與流程限制。例如預計省 30%，實際只先實現其中 60%。

初始導入成本（元）

600000

每月模型與維運成本（元）

50000

每月其他可量化效益 (元)

30000

不包含節省工時的效益，例如少付外包費、減少錯誤損失或增加可計算的收入。

每月可實現效益：NT\$ 87,600 | 每月淨效益：NT\$ 37,600
第一年淨效益：NT\$ -148,800 | 第一年 ROI：-24.8% | 估計回收期間：16.0 個月
結果未計入稅務、資金成本、風險損失與未量化效益，請用保守、基準、樂觀三種情境比較。

欄位怎麼估？

節省效益可實現比例是「理論上能省的時間」最後真正落地的比例，不是模型準確率。例如每月投入 400 小時、預計節省 30%，理論節省 120 小時；若考量人工覆核與實際使用率，只能實現 60%，就以 72 小時計入效益。

其他可量化效益是工時以外、可以換算成金額的改善，例如每月少付 30,000 元外包費。無法合理換算的品牌、士氣或長期能力提升，先不要填在這個欄位。

ROI、TCO 與成效衡量：展示成功不等於企業成功

金額只能說明一部分結果；企業還要觀察流程是否改善、成果是否可靠，以及人員是否真的採用。

除了財務 ROI，還要追蹤企業營運 KPI 的四個觀察面向

以下四個面向不是固定的 KPI 清單，而是協助管理者選擇指標的觀察框架。這些指標通常不是直接的金額，但可以用數字追蹤，幫助判斷 AI 是否真的改善了工作。



營運流程

處理時間、完成件數、等待時間、重工率。
看流程是否更快、更順，而不是只看省了多少錢。



成果品質與可靠度

錯誤率、人工修訂比例、退件率、轉人工比例。
適用於文件、客服、財務與各類知識工作。



採用與使用

實際使用人數、任務使用率、重複使用率、建議採用比例。
確認工具真的進入日常流程，而不是只有展示或試用。



風險與控制

例外事件數、人工覆核比例、權限違規次數、稽核紀錄完整度。
確認效率提升沒有換來更高的治理風險。

三種成效要分開看：ROI 衡量能換算成金額的財務效益；營運 KPI 衡量非金額、但可用數字追蹤的改善；員工信任、客戶感受與決策品質等質化變化，則需要透過訪談、回饋與持續觀察補充。

不要重複計算：處理時間縮短 30% 是營運 KPI；只有在它實際減少加班、外包或人力需求時，才可以進一步換算成 ROI。

ROI、TCO 與成效衡量：展示成功不等於企業成功

AI 專案要同時計算效益、完整成本與風險。省下的時間若沒有被重新運用，也不一定會變成財務成果。

常見的效益高估

- 用最佳示範結果代替平均日常表現。
- 只算模型費用，沒有算資料、整合、教育與治理。
- 把「節省時間」全部視為「現金節省」。
- 沒有基準線，上線後才發現無法比較前後差異。
- 只看平均值，忽略少數但代價巨大的錯誤。

例子：客服摘要工具的效益為什麼被高估？

AI 團隊估算：每月可少做 1,000 小時人工整理，每小時成本 800 元，因此每月效益是 800,000 元。

第一眼的算法： $1,000 \text{ 小時} \times 800 \text{ 元} = 800,000 \text{ 元}$ 。

重新檢查假設：實際只有 60% 的案件使用工具；其中 20% 仍需人工重做；另外每月維運成本 50,000 元。

較保守的結果： $800,000 \times 60\% \times 80\% - 50,000 = 334,000 \text{ 元 / 月}$ 的淨效益。

還要再問：這 800 小時是否真的減少加班或外包？如果只是把時間轉去做別的工作，就不能全部當成已實現的現金節省。

估算原則：先列出資料來源、使用率、可實現比例、維運成本與人工覆核，再用保守、基準、樂觀三種情境比較，不要只呈現最漂亮的數字。

講師提示 請學員用試算工具帶入自己選的場景。提醒他們做保守、基準、樂觀三次，而不是只保留最好看的答案。

ROI、TCO 與成效衡量：展示成功不等於企業成功

AI 省下工作時間，不一定會減少薪資，還可能增加模型與維運費用；企業必須重新思考任務與成本如何分配。

省下時間，不等於創造價值

AI 省下的 1,000 小時，去哪裡了？

客服團隊導入 AI 摘要與知識檢索後，每件案件平均少花 6 分鐘，換算每月約可釋放 1,000 小時。公司沒有因此立刻裁減人員，薪資支出沒有下降，反而新增了模型、整合與維運費用。

薪資沒有減少 + 新增 AI 成本 = 不能直接把 1,000 小時當成財務節省

如果工作沒有重新分配

員工可能只是被其他雜務填滿，處理量、服務品質與收入都沒有改變。

此時 AI 可能讓個人感覺比較輕鬆，但企業多付了模型費用，尚未形成可驗證的投資效益。

把釋放的時間改做更有價值的任務

1. 承接原本因等待太久而流失的客戶。
2. 主動回訪高價值客戶，降低流失率。
3. 整理常見問題，推出自助服務與新方案。

處理能力

案件完成量、等待時間、積壓案件數。

客戶收入

回訪成功率、續約率、客戶流失率。

市場機會

自助服務使用率、新方案採用率、服務範圍。

管理者要重新分配的不只是成本，也是任務：由誰使用這些時間？改做哪一項工作？要用哪個 KPI 證明結果？如果沒有明確答案，省下的時間就還不能算成企業價值。

這時 AI 的價值不是「少付幾個人的薪水」，而是用新增的模型成本，換取更大的處理能力、客戶收入與市場機會。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

前面我們在「降低幻覺的六層防線」中，用資料來源、限制與查證要求降低 AI 幻覺；當 AI 開始讀取企業資料、使用工具並完成多步驟任務時，還需要把這些防線整理成一份完整、可管理的任務說明。

五要素任務說明

C

Context 背景

說明目前情境、受眾，以及為什麼要做這件事。

T

Task 任務

說清楚要完成什麼，以及預期產出或決策用途。

D

Data 資料

指定可使用的文件、數據、系統與可信來源。

L

Limits 限制

界定資料範圍、禁止事項、權限與人工核准條件。

A

Acceptance 驗收標準

訂出正確性、格式、來源與人工確認的要求。

延伸觀念：從提示詞到工作環境。OpenAI 認為，要讓 AI Agent 可靠工作，除了說明任務，還要提供可理解的環境、工具、限制與回饋循環；NVIDIA 也指出，Agent Harness（支撐 Agent 運作的一整套工作環境）不只處理提示與上下文，還包含工具、記憶、限制與回饋機制。這些觀念都提醒管理者：交代任務之外，也要準備資料、劃定邊界並建立驗收方式。

延伸閱讀：[OpenAI：Harness engineering: leveraging Codex in an agent-first world](#)；[NVIDIA Elements：Agent Harness Guidelines Reference](#)。兩篇資料並未提出與本頁完全相同的固定五項分類；本頁是依其核心觀念，整理成管理者易用的任務說明框架。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

從模糊問題，改成可管理的任務

模糊

給 AI Agent 的指令

「祥豐電腦最近怎麼了？」

為什麼模糊

「最近」是多久？要看訂單、營收還是付款？也沒有指定比較基準、資料口徑與輸出要求。AI 很容易把風險訊號直接寫成已證實原因。

可驗證

給 AI Agent 的指令

「使用 seed.db 分析祥豐電腦 2026-02 至 2026-05 的訂單、營收與應收帳款變化；只計入已確認訂單，帳齡以 2026-05-22 為基準。每項結論須區分事實、假設與未知，並註明資料欄位及期間。輸出趨勢表、風險訊號與三項主管待確認事項；不得推測客戶已轉向競爭對手，也不得自行調整信用條件。」

為什麼可驗證

已指定分析期間、資料來源、計算口徑、輸出格式、禁止事項與人工決策邊界，主管可以回到資料逐項重算與查核。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

具體範例：分析客服等待時間為什麼變長

客服主管發現，最近三個月平日 18:00–21:00 的平均等待時間由 4 分鐘增加到 9 分鐘。因為下週例會必須決定是否調整晚間排班，他需要先讓 AI 整理現有資料、找出等待時間上升的原因並比較方案；最後排班仍由主管決定。

模擬交給 AI Agent 的指令

背景：將最近三個月分為前六週與後六週後，平日 **18:00–21:00** 的平均等待時間由 **4** 分鐘增加到 **9** 分鐘。客服主管要在下週例會決定是否調整晚間排班。

任務：先找出等待時間上升的主要日期、時段與可能原因；對每個原因列出假設、支持證據、反證或未知，再提出兩個排班調整方案，並比較對人力成本、等待時間與員工負荷的影響。

資料：只使用附件中的三個月來電與工單紀錄、排班表、請假紀錄及滿意度資料；每項結論都要註明資料欄位與日期。

限制：不得推測個別員工能力，不得揭露客戶或員工姓名；資料不足時標示「未知」。AI 不得自行決定或通知排班。

驗收標準：輸出一頁摘要、尖峰時段表及兩個方案的比較表；數字必須可以重算，假設必須清楚，並標出至少三項需要主管確認的事項，例如下月促銷活動、加班上限與臨時支援意願。

先拆解現象

- **需求增加**：18:00–21:00 的來電量或工單量是否上升？
- **處理變慢**：平均處理時間、轉接率或複雜案件比例是否改變？
- **可用人力下降**：請假、訓練、離席或技能覆蓋是否減少？

每個原因都要有證據

- **假設**：等待時間變長是因晚間來電量增加。
- **檢查**：比較前六週與後六週同時段的來電量與到達率。
- **結論**：確認、排除或標示未知，再進入排班方案。

判斷順序：增加一人是「解法」，不是「原因」。先分辨是需求增加、處理變慢，還是可用人力下降，再比較不同排班方案；如果主要原因不在人力，就不應強迫用加人解決。

分工原則：AI 先整理資料、找出異常並比較方案；主管確認資料是否合理，考量勞動規範與人員狀況後，再決定實際排班。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

AI 分析客服等待時間後，主管還要先查原因

課堂備註

一頁摘要：先找原因，再比較排班方案

資料範圍：附件三個月的來電與工單紀錄、排班表、請假紀錄及滿意度資料；以 call_time 將資料分為前六週與後六週。以下數字為課堂模擬輸出，實際報告須由附件欄位與日期重算。

初步結論：平日 18:00–21:00 平均等待時間由 4.0 分鐘升至 9.0 分鐘；需求增加與可用人力下降都值得驗證，不能只把問題歸因於少一個人。

模擬 AI 報告

原因、證據與排班方案

計算口徑：依 call_time 篩選平日 18:00–21:00，再拆成三個一小時時段；以 $AVG(wait_seconds) \div 60$ 分別計算各時段與整體的前六週、後六週平均等待分鐘。來電量以 case_id 計數後除以有效營運小時；整體平均須以每通來電計算，不能直接平均三列。正式報告須列出兩段確切日期。

尖峰時段表

時段	等待（前→後）	來電量 / 小時（前→後）	初步判讀
18:00–19:00	4.0→6.0 分	72→80 通	需求上升
19:00–20:00	4.0→11.0 分	74→96 通	主要尖峰
20:00–21:00	4.0→10.0 分	70→82 通	需求上升
18:00–21:00 整體	4.0→9.0 分	72→86 通	整體惡化

原因驗證表

主管查核

查核後，才能決定是否調整排班

- 重算數字：**用 call_time、wait_seconds 逐一重算 18:00–19:00、19:00–20:00、20:00–21:00，再確認 18:00–21:00 整體平均是否為 4.0→9.0 分鐘。
- 檢查原因：**來電量 +19% 有資料支持；8→7 人仍須查核請假與訓練紀錄；處理時間 +2% 不足以單獨解釋等待翻倍。
- 確認估算：**12 個相似班次必須具有相近的星期、促銷、案件類型與人力配置，否則 6.3 分鐘只能當參考。
- 主管決策：**補齊促銷、加班上限、支援意願與成本資料，再選擇可回復的試行方案。

查核結論：目前較支持「需求增加 + 可用人力下降」，但尚不能證明「增加一人」是唯一解法。先補資料，再由主管決定試行方案。

可能原因	支持證據（欄位 / 日期區段）	反證或未知
需求增加	call_time、case_id；同期來電 72→86 通 / 小時（+19%）	下月促銷活動是否造成尖峰，未知
可用人力下降	schedule、leave；實際上線 8→7 人	少一人是請假、訓練或臨時離席，需核對
處理變慢	work_order start/end；平均處理 5.8→5.9 分鐘（+2%）	案件類型與轉接率是否改變，需再分組

兩個排班方案比較

方案	人力成本	等待時間（估算）	員工負荷
A 調整現有人力	新增 0 工時	約 7.5 分；12 個歷史班次（每班 7 名客服同時在線、需求相近）的等待時間中位數，須以試行確認	其他時段覆蓋變薄
B 18:00–21:00 增 1 人	20 天×3 小時 ×時薪；時薪未知	約 6.3 分；12 個歷史班次（每班 8 名客服同時在線、需求相近）的等待時間中位數	晚班負荷下降，成本增加

共同假設：資料口徑一致、相似班次的來電量與案件類型可比；估算不是因果證明，正式採用前要做小型試行。


管理重點：數字要能重算，原因要有證據，行動要由有權責的人決定。AI 報告是決策材料，不是決策本身。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

Agentic AI 改變了推理經濟學

同一個問題，若交給 Agent 完成，成本不再只是一次回答的費用，而是完成一個通過驗證的任務所需的全部嘗試。



管理上的重點：Agent 的成本與風險，應以「通過驗證的任務」衡量，而不只是每百萬 tokens 的單價。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

Agent 導入容易忽略的四個管理面向



Token 膨脹

規劃、自我修正、工具回傳與長上下文，使一次 Agent 任務遠高於單輪問答。



延遲鏈

每一步都可能等待模型、資料庫或外部服務，使用者體驗取決於整條鏈。



資料與權限

Agent 越有用，通常接觸越多內部資料與工具；攻擊面與責任同步增加。



版本與維運

模型更新、退役或規則變更可能造成結果漂移；企業要決定需要多少版本控制，以及能承擔多少維運責任。

接下來怎麼看：成本、延遲與版本控制會影響部署選擇，[Chapter 09](#) 將比較雲端（Cloud）、地端（On-premises）與混合方案；下一頁先聚焦不論部署在哪裡都必須處理的工具權限與人工核准。

從清楚指令到可管理的 Agent

指令越清楚，工作越容易驗收；當 AI 能讀取資料、使用工具並採取多步驟行動，權限與控制也必須同步升級。

以費用報支為例：Agent 的工具權限怎麼分級？

無論 Agent 使用雲端 (Cloud) API 或地端 (On-premises) GPU，都不能因為模型部署在受控環境，就同時取得讀取、修改、送出與付款的完整權限。以下用費用報支流程拆解每項動作的權限邊界。

權限層級	費用報支中的例子	執行規則
讀取	讀取發票影像、金額、日期、部門與專案代碼。	可自動執行；只能讀取完成報支所需的資料，並留下查詢紀錄。
產生草稿	把發票內容填入報支單，標記可能缺少的欄位與憑證。	可自動產生；員工或財務人員確認後才能送出。
送出申請	將已確認的報支單送進簽核流程。	須確認金額、成本中心與附件完整；送出前保留人工確認或明確授權。
核准與付款	核准報支、修改付款帳戶，或觸發銀行付款。	不得由 Agent 自行執行；必須由指定主管與財務人員核准，並採雙人覆核。

判斷原則：能讀取，不代表能修改；能產生草稿，也不代表能送出或付款。越接近金錢、正式紀錄與對外承諾的動作，越需要人工核准、操作紀錄與回復機制。

落地檢查：每個 Agent 工具都要先回答三個問題：它能讀什麼？能改什麼？出錯時誰能停止並恢復？

治理、風險與內控：讓創新可以持續，而不是靠禁止或放任

治理定公司的方針、邊界與責任；管理再把它落實成流程與 SOP。

—— 虛構案例 | 曜星生活科技客服事件

上午 9:12，一份客訴資料進了公開 AI

- 09:12** 分析師上傳 12,000 筆客訴
為了趕出趨勢摘要，他把包含姓名、電話與訂單編號的資料貼進未核准的公開 AI。
- 09:18** AI 推論「產品可能過熱」
少數客戶提到「很燙」，AI 卻把零散描述放大成產品安全風險。
- 09:24** 未查證的判斷進入管理報告
客服主管直接引用摘要，沒有回看原始紀錄，也沒有請產品與品質單位確認。
- 09:31** Agent 自動寄信並發補償券
系統把報告當成核准依據，向 380 位客戶承認「疑似產品問題」。
- 10:05** 記者來電：公司是否隱瞞風險？
客戶已把信件貼上社群；但公司此刻還不知道產品是否真的有問題。

你是事業部主管

第一個動作是什麼？

- A 立即發布聲明，否認產品有問題
- B 先停止 Agent 對外寄信
- C 要求員工刪除所有對話紀錄
- D 確認資料、客戶與產品影響範圍

這不是一次 AI 答錯，而是一串錯誤都沒有被攔下。

治理、風險與內控：讓創新可以持續，而不是靠禁止或放任

治理定公司的方針、邊界與責任；管理再把它落實成流程與 SOP。

—— 事故拆解

NIST 四個動作：找出客服事故的治理缺口

這起事故不是某一位員工單獨造成的。資料、判斷、行動與責任四道防線同時失效，錯誤才一路走到客戶。

治理比管理更上位

治理先決定方針、邊界與責任；管理才設定平台、權限、測試、監控與事件 SOP。

GOVERN

治理 | 定方針與責任

決定哪些用途可以做、誰能核准、風險容忍度，以及誰有權停止系統。

本案缺口：沒有人為客服 Agent 的資料與對外行動承擔完整責任。

MAP

盤點 | 看清用途與影響

盤點使用情境、資料、使用者、受影響的人，以及系統與外部服務的連結。

本案缺口：沒有辨識客訴含個資，也沒盤點 Agent 會直接接觸客戶。

MEASURE

衡量 | 測試錯誤會多嚴重

測試準確性、可靠性、安全性與錯誤情境，並確認衡量方法是否適合用途。

本案缺口：未測試 AI 是否會把少數客訴誤判為產品安全問題。

MANAGE

管理 | 排序並處置風險

依影響與可能性排序，選擇降低、監控、停止、轉移或接受風險。

本案缺口：沒有人工關卡、寄件上限、異常告警與緊急停用機制。



NIST 的四項不是一次性的直線步驟。GOVERN 應貫穿其他功能；系統上線後，也要持續重新盤點、衡量與處置風險。

參考：NIST AI Risk Management Framework 1.0 — AI RMF Core。NIST 說明四項功能不是固定順序的檢查清單。

治理、風險與內控：讓創新可以持續，而不是靠禁止或放任

治理定公司的方針、邊界與責任；管理再把它落實成流程與 SOP。

—— 風險分級練習

同一個客服 AI，為什麼有時綠燈、有時紅燈？

這裡的燈號不是替整個 AI 系統貼標籤，而是判斷一項資料存取、判斷或行動，能不能交給 AI 自動執行。



綠燈 | 可以自動執行

低風險、範圍明確、錯誤可回復，而且有紀錄與監控。



黃燈 | AI 可以協助，但行動前要人工核准

AI 可以分析、標記或產生草稿，不能直接對客戶、財務或重要決策採取行動。



紅燈 | 不得交給 AI 自動執行

涉及敏感資料、重大權益、不可回復行動，或 AI 沒有資格作出的專業判斷。

同一個客服 AI，可能因為資料、影響、可回復性與行動權限不同而得到不同燈號。接著用四個條件判斷下面的情境：

資料是否敏感

影響是否重大

錯誤能否回復

AI 能否自行行動

逐題判斷：AI 可以自動做到哪裡？

點選每個情境的燈號，查看建議分級與理由。

情境 1 | 整理公開 FAQ

AI 把官網既有問答改寫成較容易閱讀的客服回覆草稿。

綠燈

黃燈

紅燈

情境 2 | 潤飾人員寫好的回覆

客服先完成內容，AI 只調整語氣；仍由客服人員確認後寄出。

綠燈

黃燈

紅燈

情境 3 | 分析去識別化客訴

在企業核准環境中，分析已移除姓名、電話與訂單編號的客訴趨勢。

綠燈

黃燈

紅燈

情境 4 | 標記可能的安全問題

AI 發現「過熱」描述，建立內部警示並送交產品與品質單位覆核。

綠燈

黃燈

紅燈

情境 5 | 自動發放小額補償

Agent 依明確規則提出 200 元以下補償建議，實際發放前仍轉人工核准。

綠燈

黃燈

紅燈

情境 6 | 自動承認產品缺陷

把含個資的客訴貼進公開 AI，並讓 Agent 直接向客戶承認缺陷與承諾賠償。

綠燈

黃燈

紅燈

最重要的觀念：不是替整個 AI 系統貼一種顏色，而是替每一項資料存取、判斷與行動分別設定燈號。

治理、風險與內控：讓創新可以持續，而不是靠禁止或放任

治理定公司的方針、邊界與責任；管理再把它落實成流程與 SOP。

事件應變

事故後的前 30 分鐘：先止血，再查清事實

治理先指定誰有權停止、誰負責決定與通報；管理依照事件 SOP 完成六個動作。



記者正在等回覆

「貴公司是否早已知道產品有過熱風險？」

事件處理的第一目標不是找人究責，而是停止擴散、保存事實並保護受影響的人。

治理、風險與內控：讓創新可以持續，而不是靠禁止或放任

治理先決定企業需要控制什麼；部署架構再把資料、版本、服務與責任邊界落實到系統中。

從治理要求，推導部署需求

客服事故不只暴露流程問題，也提出一個架構問題：現有的雲端 (Cloud) API 能否滿足公司的控制要求，還是需要企業內部環境？



資料邊界

客訴個資不能進入未核准的公開 AI；敏感資料必須留在核准環境。



版本可重現性

雲端模型名稱或別名背後的行為可能更新，使提示、工具呼叫或既有 Agent Harness 退化；企業必須能辨識版本並回歸測試。



服務持續性

企業可以停止自己的 Agent；部署差異在於是否需要自行掌握推論容量、網路依賴、維護窗口與復原時間。



成本可控性

Agent 的多步推理、長上下文與重試會放大 Token 費用；用量大量且穩定時，要比較雲端按量成本與地端完整 TCO。

地端 (On-premises) 可以增加的控制

- 敏感資料與推論留在企業環境。
- 固定模型權重、推論環境與更新時點，測試後再切換或回復。
- 控制 GPU 容量、佇列與服務優先順序。
- 把按 Token 波動的支出轉為可規劃的算力容量，但仍須管理硬體、電力、維運與利用率。

地端 (On-premises) 不會自動解決

- AI 幻覺、錯誤判斷與資料品質。
- 模型或 Agent Harness 的回歸測試與監控。
- Agent 停止開關、工具權限、人工核准與決策責任。
- 事件應變、教育與管理 SOP。

不是所有情境都需要地端：如果核准的雲端服務能提供合適的資料條款、模型版本政策、退役通知、紀錄與服務承諾，仍可採用雲端；當企業需要固定模型行為、敏感資料不能離開，或 Agent 用量大量且長期穩定時，地端部署的需求才會提高。

治理先決定邊界，部署再實現邊界。地端 (On-premises) 不是治理本身，而是取得資料、版本與推論服務自主性的一種方式。下一章將比較雲端、地端與混合部署如何滿足不同工作負載。

注意

課堂展示，不等於正式上線架構：課程中由 Codex 依照 Skill 直接讀取模擬 ERP 的 seed.db，只為示範資料分析。Skill 可以規定工作步驟與工具用法，但不是登入與授權邊界，通常會繼承執行環境的帳號、檔案與資料庫權限。正式環境應讓 Skill 負責工作方法，由 ERP 或受控整合層的 MCP Server 串接企業身分驗證系統，將查詢、建立草稿、送出與修改拆成不同工具，並落實角色、資料範圍、金額上限、人工核准與稽核紀錄。若 ERP 資料不得離開企業環境，LLM 與 Agent Harness 也必須部署於地端 (On-premises)，不得把資料或上下文送往雲端模型。

雲端（Cloud）、地端（On-premises）與混合部署：沒有絕對最好，只有是否適合工作負載

部署選擇是成本、資料、延遲、彈性與維運能力的綜合決策。

面向	雲端	地端	混合
初始投入	通常較低，可快速試用	硬體與建置較高	依核心與彈性需求分配
長期成本	隨用量、token 與服務變動	較固定，但需利用率足夠	可將穩定工作留地端、尖峰放雲端
資料控制	依供應商、區域與契約	可完整留在企業環境	敏感資料留地端、非敏感使用雲端
擴充速度	快速、彈性	受採購與機房限制	兼顧基礎容量與彈性
最新能力	通常較快取得	需自行測試、更新與維護	依任務選用不同模型
延遲與穩定	受網路與服務狀況影響	低延遲、較可預測	關鍵流程本地，其他彈性分配
責任	供應商與企業共同責任	企業承擔更多維運與安全責任	架構與權責較複雜，需清楚治理

互動工具：部署方向初步判斷

回答五題後取得方向。這不是採購建議，正式決策仍需資安、IT、財務與業務共同評估。

資料敏感度

中：內部非公開資料

使用量型態

逐步成長

延遲與離線需求

希望穩定

內部維運能力

可維護一般系統

需要最新模型的速度

可經測試後更新

目前方向：混合部署

將敏感或穩定工作放在受控環境，將需要彈性、尖峰容量或最新模型的工作放在雲端。

雲端 (Cloud) 、地端 (On-premises) 與混合部署：沒有絕對最好，只有是否適合工作負載

部署選擇是成本、資料、延遲、彈性與維運能力的綜合決策。

常見的漸進策略

快速驗證

先用核准雲端服務

以公開或去識別化資料測試價值、使用量與流程，避免一開始就投入大型基礎設施。

建立混合

敏感資料與穩定工作受控

將資料檢索、權限與部分推論放在企業環境，保留雲端模型的彈性。

規模化

以實際工作負載決定地端容量

當使用量、成本與資料需求明確，再做 TCO 與地端 / 私有雲投資。

不要只比較模型價格：完整 TCO 還包括資料整理、整合、網路、硬體、電力、維運、備援、監控、安全、教育與退出成本。

把 AI 應用帶回工作：從一個問題開始

不必先決定要開發哪一種 Agent；先找出工作中值得改善的問題，再判斷 AI 可以協助哪一步。

想一個 AI 可以幫忙的工作問題

從自己熟悉的工作開始。不要先問「要用哪個模型」，先問「哪一件事如果做得更快、更準確，會產生實際價值」。

工作痛點

哪件事值得改善？

耗時、重複、資料分散、容易遺漏，或經常需要整理與比較。

AI 的角色

AI 可以協助哪一步？

搜尋、整理、摘要、分類、比較、產生草稿，或在規則內有限執行。

使用者

誰會使用結果？

結果要幫助誰完成工作、判斷問題或準備決策？

人的責任

哪一步仍由人決定？

確認事實、處理例外、核准行動，並對最後結果負責。

我想利用 AI 協助_____，讓_____可以更快／更準確地完成_____；AI 可以先做_____，但_____仍由人確認或決定。

例子：我想利用 AI 協助整理 ERP 中的銷售與應收異常，讓業務主管更快找到需要優先確認的客戶；AI 可以整理訊號與證據，但客戶聯繫及信用條件仍由業務與財務主管決定。

把 AI 應用帶回工作：從一個問題開始

好的 AI 構想不只要看起來有用，也要能控制風險、實際執行並證明有效。

用四個問題檢查這個想法

有價值

解決什麼問題？

- 目前浪費多少時間或造成什麼影響？
- 誰會因為改善而受益？

風險可控

錯了會發生什麼？

- 會接觸哪些敏感資料或重要權益？
- 哪一步必須人工核准？

可執行

現在做得到嗎？

- 資料、工具與負責人是否已經存在？
- 能否先從小範圍開始？

可驗證

怎麼知道有效？

- 目前的時間、品質或錯誤基準是什麼？
- 要用哪一個 KPI 比較前後差異？

檢查後，只需要做一個下一步判斷

可以先試

四個問題都有基本答案，先做小而可回復的測試。

先做準備

價值明確，但資料、流程、權限或 KPI 還不清楚，先補齊再測試。

目前不做

風險過高、無法驗證，或 AI 必須作出不適合委派的重大判斷。

重點：不是每個想法都要進入開發；能清楚決定「先試、先準備或目前不做」，本身就是管理成果。

把 AI 應用帶回工作：從一個問題開始

第一步不必正式上線。先用低風險資料保留原流程，確認 AI 是否真的帶來可重算、可比較的改善。

怎麼開始：做一個小而可回復的測試

1

選小範圍

選擇 10~20 個歷史案例、去識別資料或低風險工作，不直接影響客戶與正式決策。

2

留下原始基準

先記錄目前花費時間、品質、錯誤率或處理量，避免測試後無法比較。

3

說清楚工作

指定背景、任務、資料、限制與驗收標準，並保留使用過的指令與版本。

4

設定人工關卡

AI 先分析或產生草稿；涉及對外訊息、金錢、權益或重要行動時必須人工核准。

5

平行比較

保留原流程，同時比較 AI 協助後的時間、品質、錯誤與人工負荷。

6

決定下一步

依證據決定擴大、修改、補資料或停止，不因一次成功展示就直接正式上線。

我回去後的第一步是_____；我要找_____一起確認，使用_____資料做小型測試，並用_____判斷是否有效。

最後帶走四句話：先確認有價值，再確認風險可控；從做得到的小範圍開始，用 KPI 證明是否有效。AI 可以協助工作，但方向、核准與責任仍由人掌握。

資料來源與更新提醒

法規、模型、成本與產品規格變化快速；引用資料或用於決策前，應確認發布日期與最新版本。

主要官方資料

1. 行政院及所屬機關（構）使用生成式 AI 參考指引：安全、隱私、資料治理、問責、自主與控制。
2. NIST AI Risk Management Framework：AI 風險治理、盤點、衡量與管理。
3. NIST Generative AI Profile (NIST AI 600-1)：生成式 AI 特有或被放大的風險與建議行動。
4. OECD：2025 年個人與企業 AI 採用資料：本教材採用的 20.2%、52.0% 與 17.4% 數據來源。
5. European Commission：AI Act 官方說明：國際風險分級、AI 素養與治理趨勢。